

UNIVERSITÀ DEGLI STUDI DI
NAPOLI FEDERICO II



CORSO DI LAUREA MAGISTRALE IN INGEGNERIA
INFORMATICA

DIPARTIMENTO DI INGEGNERIA ELETTRICA E DELLE
TECNOLOGIE DELL'INFORMAZIONE

Big Data Homework 1

Candidati:

Vincenzo D'Angelo M63001595

Giorgio Di Costanzo M63001579

Professore:

Vincenzo Moscato

Anno Accademico 2024/2025

Contents

1	Introduzione	1
1.1	Dataset	1
2	Preparazione dell'ambiente	3
2.1	Setup e installazione	3
2.2	Caricamento del dataset	3
3	Analisi	4
3.1	Analisi 1: Studi per cui si prevede una durata maggiore	4
3.2	Analisi 2: Studi completati in minor tempo	6
3.3	Analisi 3: Condizioni mediche più studiate in Italia nell'ultimo anno	8
3.4	Analisi 4: Campi di ricerca con il più alto interesse mediatico . .	10
3.5	Analisi 5: AHC con la più alta percentuale di studi su anziani e minori	11
3.6	Analisi 6: Rapporto tra durata attesa e numero di partecipanti per ogni fase	14
3.7	Analisi 7: Durata stimata media e numero medio di partecipanti per tipologia di studio	15
3.8	Analisi 8: Durata stimata media, numero medio di partecipanti e attenzione mediatica media per ogni categoria HRCS	16
3.9	Analisi 9: Durata media degli studi sul cancro al seno in funzione dell'attenzione mediatica	18
3.10	Analisi 10: Top 2 sponsor/collaboratori con più sperimentazioni per ogni tipo di cancro	20

1 Introduzione

L'obiettivo dell'elaborato è svolgere una serie di analisi esplorative su un dataset di trial clinici, facendo uso degli strumenti offerti da PySpark. Gli studi clinici rappresentano ricerche scientifiche condotte su esseri umani, con l'obiettivo di verificare la sicurezza e l'efficacia di terapie, farmaci, dispositivi medici o procedure sanitarie.

1.1 Dataset

Il dataset fornito proviene da Dimensions.ai, una piattaforma che raccoglie dati sulla ricerca scientifica a livello globale. Ogni riga del dataset rappresenta un trial clinico. Alcune colonne contengono dati strutturati o annidati, come elenchi di condizioni mediche, organizzazioni coinvolte o località.

Colonna	Descrizione
Rank	Posizione numerica o classifica assegnata a ciascun trial.
Trial ID	Identificativo univoco dello studio clinico.
Title	Titolo completo dello studio.
Brief title	Versione abbreviata del titolo.
Acronym	Acronimo dello studio clinico.
Abstract	Riassunto o sinossi dello studio, con una breve descrizione degli obiettivi, dei metodi e degli aspetti principali.
Start date	Data di inizio dello studio clinico.
Start Year	Anno di inizio dello studio.
End Date	Data prevista o effettiva di fine dello studio.
Completion Year	Anno in cui lo studio è stato completato.
Phase	Fase dello studio clinico.
Study Type	Tipologia dello studio.
Study Design	Descrizione della struttura metodologica dello studio.
Conditions	Elenco delle condizioni mediche oggetto dello studio.
Recruitment Status	Stato del reclutamento dei partecipanti.
Number of Participants	Numero previsto o effettivo dei partecipanti arruolati.
Intervention	Descrizione del trattamento o intervento sperimentale utilizzato nello studio.
Gender	Genere dei partecipanti coinvolti.
Age	Fasce di età dei partecipanti allo studio.
Registry	Nome del registro in cui è elencato lo studio clinico.
Investigators/ Contacts	Informazioni sui ricercatori principali e contatti dello studio.

Colonna	Descrizione
Sponsors/ Collaborators	Enti o organizzazioni che finanziano e/o collaborano allo studio.
City of Sponsor/- Collaborator	Città associata allo sponsor o collaboratore.
State of Sponsor/- Collaborator	Stato o provincia dell'organizzazione sponsor o collaboratrice.
Country of Sponsor/Collaborator	Paese dello sponsor o collaboratore.
Collaborating Funders	Altri enti finanziatori coinvolti nella collaborazione.
Funder Group	Gruppo o categoria di appartenenza dell'ente finanziatore.
Funder Country	Paese d'origine dell'ente finanziatore.
Source Linkout	Collegamento esterno alla fonte o al sito ufficiale dello studio.
Altmetric Attention Score	Punteggio che indica l'attenzione mediatica ricevuta dallo studio.
Dimensions URL	Collegamento alla piattaforma Dimensions per dettagli bibliometrici o scientifici dello studio.
Fields of Research (ANZSRC 2020)	Ambiti di ricerca secondo la classificazione ANZSRC 2020.
RCDC Categories	Categorie di ricerca secondo il sistema RCDC.
HRCS HC Categories	Categorie sanitarie secondo il sistema HRCS.
HRCS RAC Categories	Categorie HRCS relative all'allocazione delle risorse.
Cancer Types	Tipologie di cancro studiate, se presenti.
CSO Categories	Categorie secondo il sistema CSO.
AHC	Informazioni relative ai Centri Accademici Sanitari coinvolti nello studio.

Table 1: Legenda delle colonne del dataset dei trial clinici

2 Preparazione dell'ambiente

2.1 Setup e installazione

Le seguenti righe di codice consentono di scaricare e installare la versione 3.4.4 di Spark direttamente dai mirror ufficiali Apache. Ricordiamo che Spark richiede Java per funzionare

```
1 !apt-get install openjdk-8-jdk-headless -qq > /dev/null
2 !wget -q https://archive.apache.org/dist/spark/spark-3.4.4/
   spark-3.4.4-bin-hadoop3.tgz
3 !tar xf spark-3.4.4-bin-hadoop3.tgz
4 !pip install -q findspark
```

Codice 1: Installazione di Spark

Successivamente, sono state configurate le variabili di ambiente per Java e Spark e si è proceduto con l'inizializzazione di findspark e la creazione di un contesto.

```
1 import os
2 os.environ["JAVA_HOME"] = "/usr/lib/jvm/java-8-openjdk-amd64"
3 os.environ["SPARK_HOME"] = "/content/spark-3.4.4-bin-hadoop3"
4
5 import findspark
6 findspark.init()
7 from pyspark.context import SparkContext
8 sc = SparkContext.getOrCreate()
```

Codice 2: Inizializzazione di Spark

2.2 Caricamento del dataset

A partire dal contesto definito, è stata creata una sessione per il caricamento del dataset, specificando intestazioni, caratteri di escape e delimitazione.

```
1 from pyspark.sql import SparkSession
2 spark = SparkSession(sc)
3 #sc = SparkContext.getOrCreate()
4 df = spark.read.option("header", "true") \
5     .option("inferSchema", "true") \
6     .option("multiline", "true") \
7     .option("escape", "'") \
8     .option("quote", "'") \
9     .option("mode", "PERMISSIVE") \
10    .csv("dimensions_clinicalTrials.csv")
```

Codice 3: Caricamento del dataset

3 Analisi

In questa sezione vengono descritte le analisi condotte sul dataset. Per ogni analisi sarà specificato l'obiettivo, la descrizione e il codice utilizzato e verrà riportato uno screenshot dei risultati ottenuti.

3.1 Analisi 1: Studi per cui si prevede una durata maggiore

- **Obiettivo:** Individuare gli studi clinici con la durata attesa più lunga.
- **Descrizione:** Si convertono le colonne “*Start Date*” e “*End Date*” dal formato stringa al formato data e si filtrano le righe con date mancanti e con data di fine oltre il 2025. I dati vengono raggruppati per ID, considerando la data di inizio più precoce e quella di fine più tarda. Si calcola quindi la durata di ogni singolo studio come differenza in anni tra data di fine e data di inizio e si ordinano i risultati in maniera crescente.

```
1 from pyspark.sql.functions import to_date,
   months_between, year, datediff, min, max, round,
   when
2
3 df_dates = df.withColumn("Start Date", to_date(col("
   Start Date"), "dd/MM/yyyy")) \
4     .withColumn("End Date", to_date(col("End Date"
   ), "dd/MM/yyyy")) \
5     .filter(col("Start Date").isNotNull())\
6     .filter(col("End Date").isNotNull())\
7     .filter(year(col("End Date"))>2025)\
8     .groupBy("Trial ID")\
9     .agg(
10         min(col("Start Date")).alias("Start Date"),
11         max(col("End Date")).alias("End Date")
12     )\
13     .withColumn("Expected Duration (years)", round
   (months_between(col("End Date"), col("
   Start Date"))/12, 2))\
14     .orderBy("Expected Duration (years)",
   ascending = False)\
15     .show(truncate=False)
```

Codice 4: Studi per cui si prevede una durata maggiore

Trial ID	Start Date	End Date	Expected Duration (years)
NCT03553420	2017-12-16	2068-01-01	50.04
NCT01574053	2012-07-01	2062-01-01	49.5
NCT02440763	2005-07-01	2050-07-01	45.0
NCT02699736	1994-01-01	2030-12-01	36.92
NCT04725422	2018-08-01	2050-08-01	32.0
NCT03807687	2016-12-01	2046-12-01	30.0
NCT05845801	2022-12-07	2052-09-30	29.81
NCT05925699	2023-09-01	2052-09-01	29.0
NCT05522374	2012-06-14	2040-12-01	28.47
NCT00330447	2005-08-01	2032-12-01	27.33
NCT02832245	2001-03-01	2027-12-01	26.75
NCT01007474	2004-01-01	2030-01-01	26.0
NCT04036357	2011-11-01	2036-12-31	25.16
NCT04982744	2020-07-02	2045-07-01	25.0
NCT05247645	2020-10-10	2045-10-09	25.0
NCT06016946	2023-06-28	2048-01-28	24.58
NCT01704716	2002-02-01	2026-09-01	24.58
NCT00070564	2003-11-01	2027-01-01	23.17
NCT01942603	2009-07-01	2031-12-01	22.42
NCT01922440	2013-07-30	2034-11-30	21.33

only showing top 20 rows

Figure 1: Studi per cui si prevede una durata maggiore

3.2 Analisi 2: Studi completati in minor tempo

- **Obiettivo:** Identificare gli studi clinici con la durata effettiva più breve, misurata in giorni.
- **Descrizione:** Si convertono le colonne “*Start Date*” e “*End Date*” dal formato stringa al formato data e si filtrano le righe con date mancanti. I dati vengono raggruppati per ID, considerando la data di inizio più precoce e quella di fine più tarda. Si calcola quindi la durata di ogni singolo studio come differenza in giorni tra data di fine e data di inizio e si ordinano i risultati in maniera crescente.

```
1 df_dates2 = df.withColumn("Start Date", to_date(col("
    Start Date"), "dd/MM/yyyy")) \
2     .withColumn("End Date", to_date(col("End Date"
    ), "dd/MM/yyyy")) \
3     .filter(col("Start Date").isNotNull())\
4     .filter(col("End Date").isNotNull())\
5     .groupBy("Trial ID")\
6     .agg(
7         min("Start Date").alias("Start Date"),
8         max("End Date").alias("End Date"),
9     )\
10    .withColumn("Duration (days)", round(datediff(
        col("End Date"), col("Start Date")), 2))\
11    .orderBy("Duration (days)", ascending = True)\
12    .select("Trial ID", "Start Date", "End Date", "
        Duration (days)")\
13    .show(truncate=False)
```

Codice 5: Studi completati in minor tempo

Trial ID	Start Date	End Date	Duration (days)
NCT03832673	2019-05-22	2019-05-22	0
NCT04930172	2022-10-30	2022-10-30	0
NCT00054392	2001-09-01	2001-09-01	0
NCT03962608	2021-01-31	2021-01-31	0
NCT04391218	2021-05-01	2021-05-01	0
NCT05412706	2023-09-04	2023-09-04	0
EUPAS50139	2022-12-12	2022-12-12	0
EUPAS48420	2022-07-29	2022-07-29	0
NCT01501370	2012-01-01	2012-01-01	0
DRKS00028535	2021-05-27	2021-05-31	4
NCT05197868	2022-01-20	2022-01-26	6
NCT04698694	2020-12-09	2020-12-21	12
NCT04247490	2019-12-17	2019-12-31	14
NCT04897152	2021-08-15	2021-08-31	16
NCT05430503	2022-05-24	2022-06-15	22
NCT05986032	2023-09-01	2023-09-24	23
NCT05688189	2023-01-18	2023-02-15	28
NCT03210948	2019-01-23	2019-02-20	28
NCT04944108	2021-12-16	2022-01-14	29
NCT04895176	2021-06-01	2021-06-30	29

only showing top 20 rows

Figure 2: Studi completati in minor tempo

3.3 Analisi 3: Condizioni mediche più studiate in Italia nell'ultimo anno

- **Obiettivo:** Identificare le condizioni mediche più studiate negli studi clinici sponsorizzati da enti italiani nell'ultimo anno.
- **Descrizione:** Il dataset viene preprocessato in modo da filtrare righe con valori nulli e gestire valori multipli delle colonne “*Conditions*” e “*Country of Sponsor/Collaborator*”. Per capire quali condizioni sono state studiate nell'ultimo anno, sono state considerate solo le righe con valore di “*End Date*” maggiore di 2025, in modo da considerare tutte quelle già iniziate ma non ancora concluse. Si selezionano gli studi con sponsor/collaboratori in Italia, si raggruppano le sperimentazioni per condizione medica e si conta il numero di studi, ordinando in maniera crescente i risultati.

```
1 df.withColumn("Conditions", split(col("Conditions"), ";"))\
2   .withColumn("Conditions", explode(col("Conditions")))\
3   .withColumn("Country of Sponsor/Collaborator", split(\
4     col("Country of Sponsor/Collaborator"), "; "))\
5   .withColumn("Country of Sponsor/Collaborator", explode(\
6     col("Country of Sponsor/Collaborator")))\
7   .filter(col("Conditions").isNotNull())\
8   .filter(year(col("End Date")) > 2025)\
9   .filter(col("Country of Sponsor/Collaborator")=="Italy")\
10  .groupBy("Conditions") \
11  .count() \
12  .withColumnRenamed("count", "Number of Medical\
    Conditions") \
13  .orderBy("Number of Medical Conditions", ascending =\
    False)\
14  .show(truncate = False)
```

Codice 6: Condizioni mediche più studiate in Italia nell'ultimo anno

Conditions	Number of Medical Conditions
Follicular Lymphoma	2060
Breast Cancer	1427
Melanoma	699
Uveitis	693
Still Disease	684
Primary Sclerosing Cholangitis	684
Scleritis	684
PFAPA Syndrome	684
Schnitzler Syndrome	684
Vexas Syndrome	684
Hereditary Autoinflammatory Diseases	684
Behcet Syndrome	684
Autoinflammatory Syndrome, Unspecified	684
Classical Hodgkin Lymphoma	652
Gastro-entero Pancreatic Neuroendocrine Tumors	592
Non-Hodgkin Lymphoma, B-cell	570
Early Breast Cancer	545
Acute Myeloid Leukemia	543
Primary Biliary Cholangitis	477
Diffuse Large B-Cell Lymphoma	474

only showing top 20 rows

Figure 3: Condizioni mediche più studiate in Italia nell'ultimo anno

3.4 Analisi 4: Campi di ricerca con il più alto interesse mediatico

- **Obiettivo:** Analizzare quali campi di ricerca (secondo la classificazione *ANZSRC 2020*) ottengono in media il punteggio di *Altmetric Attention Score* più elevato.
- **Descrizione:** Il dataset viene elaborato in modo da considerare ogni campo di ricerca come riga separata. Le righe con i campi nulli vengono filtrate. Per ogni campo di ricerca, si calcola la media del punteggio Altmetric Attention Score. Il risultato è arrotondato e ordinato in ordine crescente per mostrare i campi con il punteggio medio più elevato.

```

1 df.withColumn("Fields of Research (ANZSRC 2020)", split
    (col("Fields of Research (ANZSRC 2020)"), "; "))\
2 .withColumn("Fields of Research (ANZSRC 2020)",
    explode(col("Fields of Research (ANZSRC 2020)")))\
3 .filter(col("Fields of Research (ANZSRC 2020)").
    isNotNull())\
4 .groupBy("Fields of Research (ANZSRC 2020)") \
5 .agg(round(avg("Altmetric Attention Score"),2).alias("
    Avg Altmetric Attention Score")) \
6 .orderBy("Avg Altmetric Attention Score", ascending =
    False)\
7 .show(truncate = False)

```

Codice 7: Campi di ricerca con il più alto interesse mediatico

Fields of Research (ANZSRC 2020)	Avg Altmetric Attention Score
5202 Biological Psychology	142.09
52 Psychology	135.77
3213 Paediatrics	122.75
4003 Biomedical Engineering	122.64
3101 Biochemistry and Cell Biology	121.35
3212 Ophthalmology and Optometry	117.22
40 Engineering	103.29
3203 Dentistry	91.2
4806 Private Law and Civil Obligations	82.0
4102 Ecological Applications	77.0
41 Environmental Sciences	77.0
32 Biomedical and Clinical Sciences	70.54
3202 Clinical Sciences	70.34
3211 Oncology and Carcinogenesis	67.68
4203 Health Services and Systems	53.28
31 Biological Sciences	48.13
42 Health Sciences	45.58
3201 Cardiovascular Medicine and Haematology	44.82
3204 Immunology	37.74
3207 Medical Microbiology	34.96

only showing top 20 rows

Figure 4: Campi di ricerca con il più alto interesse mediatico

3.5 Analisi 5: AHC con la più alta percentuale di studi su anziani e minori

- **Obiettivo:** Rilevare i centri accademici con le maggiori percentuali di studi clinici pediatrici e senior.
- **Descrizione:** Il dataset viene filtrato per escludere le righe che non presentano alcun range di età. Successivamente, si estraggono gli estremi degli intervalli e li si converte in anni, al fine di categorizzare gli studi in quattro gruppi:
 - Pediatric (età massima < 18),
 - Senior (età minima ≥ 65),
 - Mixed (intervalli che includono sia minori che adulti),
 - Adult (tutti i restanti casi).

Infine, si aggregano i dati per AHC, si calcolano le percentuali di studi per ciascuna categoria e si ordinano in maniera decrescente quelle relative agli studi pediatrici e senior.

```
1 from pyspark.sql.functions import col, count, sum, when
  , round, regexp_extract
2
3 # Funzione di conversione ad anni
4 def convert_to_years(value_col, unit_col):
5     return when(unit_col.contains("Year"), value_col) \
6         .when(unit_col.contains("Month"), value_col / 12) \
7         .when(unit_col.contains("Week"), value_col / 52) \
8         .when(unit_col.contains("Day"), value_col / 365) \
9         .otherwise(None)
10
11 # Rimuove solo righe in cui entrambi i valori sono N/A
  o None
12 df_filtered = df.filter(~col("Age").rlike("(?i)^(N/A|None) \
  s*-\s*(N/A|None)$"))
13
14 # Estrai gli estremi degli intervalli
15 df_extracted = df_filtered.withColumn("Age Min Value",
16     when(col("Age").rlike("(?i)^(N/A|None)"), None)
17     .otherwise(regexp_extract(col("Age"), r"^(\\d+)",
18         1).cast("float"))) \
19     .withColumn("Age Max Value",
20     when(col("Age").rlike("(?i)-(?:\\s*)?(N/A|None)$"),
21         None)
```

```

20         .otherwise(regexp_extract(col("Age"), r"-\\s*(\\d+
           ", 1).cast("float"))) \\
21     .withColumn("Age Min Unit",
22         when(col("Age").rlike("(?i)^(N/A|None)"), None)
23         .otherwise(regexp_extract(col("Age"), r"^(\\d+)\\s
           *(\\w+)", 2))) \\
24     .withColumn("Age Max Unit",
25         when(col("Age").rlike("(?i)-(?:\\s*)?(N/A|None)$"),
           , None)
26         .otherwise(regexp_extract(col("Age"), r"-\\s*(\\d+
           \\s*(\\w+)", 2)))
27
28     # Creazione categorie
29     df_cleaned=df_extracted.withColumn("Age Min Years",
           convert_to_years(col("Age Min Value"), col("Age Min
           Unit")))) \\
30     .withColumn("Age Max Years", convert_to_years(col("
           Age Max Value"), col("Age Max Unit")))) \\
31     .withColumn("Age Group", when(col("Age Max Years") <
           18, "Pediatric")
32         .when(col("Age Min Years") >= 65,
           "Senior")
33         .when((col("Age Min Years") < 18)
           & (col("Age Max Years") > 18),
           "Mixed")
34         .otherwise("Adult"))
35
36     # Aggregazione per AHC con conteggi per ciascuna
           categoria
37     df_summary = df_cleaned.groupBy("AHC").agg(
38         count("*").alias("Total Studies"),
39         sum(when(col("Age Group") == "Pediatric", 1).
           otherwise(0)).alias("Pediatric Studies"),
40         sum(when(col("Age Group") == "Adult", 1).otherwise
           (0)).alias("Adult Studies"),
41         sum(when(col("Age Group") == "Senior", 1).otherwise
           (0)).alias("Senior Studies"),
42         sum(when(col("Age Group") == "Mixed", 1).otherwise
           (0)).alias("Mixed Studies")
43     ).withColumn("Pediatric %", round(col("Pediatric
           Studies") / col("Total Studies") * 100, 2)) \\
44     .withColumn("Adult %", round(col("Adult Studies") /
           col("Total Studies") * 100, 2)) \\
45     .withColumn("Senior %", round(col("Senior Studies") /
           col("Total Studies") * 100, 2)) \\
46     .withColumn("Mixed %", round(col("Mixed Studies") /
           col("Total Studies") * 100, 2))
47
48     # Visualizza i top AHC per Pediatric
49     df_summary.select("AHC", "Pediatric %") \\

```

```

50 .orderBy(col("Pediatric %").desc_nulls_last()) \
51 .show(truncate=False)
52
53 # Visualizza i top AHC per Senior
54 df_summary.select("AHC", "Senior %") \
55 .orderBy(col("Senior %").desc_nulls_last()) \
56 .show(truncate=False)

```

Codice 8: AHC con la più alta percentuale di studi su anziani e minori

AHC	Pediatric %	AHC	Senior %
IRCCS_BURLOGAROFILO	50.0	IRCCS_INRCA	33.33
IRCCS_MEYER	41.59	IRCCS_CROB	8.0
IRCCS_GASLINI	36.02	IRCCS_SPALLANZANIROMA	7.14
AOUSSN_GMARTINO	14.4	IRCCS_CRO	5.69
IRCCS_CAGRANDA	8.95	AOUSSN_SASSARI	5.56
AOUSSN_CAGLIARI	8.57	IRCCS_IOV	4.37
AOU_SANGIOVANNIDIDIO	8.33	IRCCS_RIZZOLI	4.04
AOUSSN_FEDERICOII	7.81	IRCCS_AUSLREGGIOEMILIA	3.57
IRCCS_BESTA	7.78	AOUSSN_POLICLINICOBARI	3.46
AOU_PADOVA	7.46	IRCCS_TUMORIBARI	3.39
IRCCS_BONINOPULEJO	7.14	AOU_SANTANDREA	3.26
AOUSSN_VITTORIOEMANUELE	6.48	AOU_RIUNITIANCONA	3.24
AOU_NOVARAGALLIATE	6.25	IRCCS_SANGERARDO	3.22
AOU_VERONA	5.98	AOU_CITTADELLASCIENZA	3.01
IRCCS_INRCA	5.56	IRCCS_ISNB	2.94
IRCCS_SANGERARDO	4.23	AOUSSN_VITTORIOEMANUELE	2.78
IRCCS_SANMATTEO	3.82	AOU_MODENA	2.62
AOUSSN_VANVITELLI	3.45	AOU_CAREGGI	2.49
AOUSSN_UMBERTOI	3.44	AOUSSN_GMARTINO	2.4
IRCCS_SANTORSOLA	3.23	AOU_SENESE	2.38

only showing top 20 rows

(a) Categoria Pediatric

(b) Categoria Senior

Figure 5: AHC con la più alta percentuale di studi su anziani e minori

3.6 Analisi 6: Rapporto tra durata attesa e numero di partecipanti per ogni fase

- **Obiettivo:** Valutare, per ogni fase, come varia la durata prevista degli studi in funzione del numero di partecipanti.

- **Descrizione:** Viene creata la colonna “*Duration*”, calcolata come differenza tra “*End Date*” e “*Start Date*”.

Il dataset viene filtrato per escludere le righe con valori nulli nei campi: “*Duration*”, “*Number of Participants*” e “*Phase*”. Si aggregano i dati per fase, e per ogni fase si calcola la media della durata, la media del numero di partecipanti e il loro rapporto, in modo da capire quanti giorni servono in media per ogni partecipante. Infine, si ordinano i dati per fase crescente.

```

1 df.withColumn("Duration",datediff(to_date(col("End Date
  "), "yyyy-MM-dd"), to_date(col("Start date"), "yyyy
    -MM-dd")))\
2 .filter((df_new.Phase.isNotNull()) & (df["Number of
    Participants"].isNotNull()))\
3 .filter(col("Duration").isNotNull())\
4 .groupBy("Phase")\
5 .agg(
6     round(avg("Duration"), 2).alias("
        Media_Durata_Prevista"),
7     round(avg("Number of Participants"), 2).alias("
        Media_Partecipanti"),
8     round(avg("Duration") / avg("Number of Participants
        "), 2).alias("Giorni_per_Partecipante")
9 )\
10 .select("Phase", "Media_Durata_Prevista", "
    Media_Partecipanti", "Giorni_per_Partecipante")\
11 .orderBy("Phase")\
12 .show(truncate=False)

```

Codice 9: Rapporto tra durata attesa e numero di partecipanti per ogni fase

Phase	Media_Durata_Prevista	Media_Partecipanti	Giorni_per_Partecipante
Phase 1	1510.56	98.59	15.32
Phase 1/2	1958.93	164.82	11.88
Phase 2	1701.0	149.41	11.38
Phase 2/3	1748.98	733.27	2.39
Phase 3	2039.25	886.57	2.3
Phase 3/4	876.0	315.0	2.78
Phase 4	1413.27	505.49	2.8
Post Authorisation Studies	1023.27	57036.82	0.02

Figure 6: Rapporto tra durata attesa e numero di partecipanti per ogni fase

3.7 Analisi 7: Durata stimata media e numero medio di partecipanti per tipologia di studio

- **Obiettivo:** Analizzare, per ogni tipologia di studio, la durata media prevista e il numero medio di partecipanti richiesti.

- **Descrizione:** Viene creata la colonna “Duration”, calcolata come differenza tra “End Date” e “Start Date”.

Il dataset viene filtrato per escludere le righe con valori nulli nei campi: “Duration”, “Number of Participants” e “Study Type”. Si aggregano i dati per tipologia di studio e, per ogni tipologia, si calcolano la media della durata e la media del numero di partecipanti. Infine, si ordinano i dati in modo crescente rispetto alla durata media.

```
1 df.withColumn("Duration", datediff(to_date(col("End
    Date"), "yyyy-MM-dd"), to_date(col("Start date"), "
    yyyy-MM-dd"))) \
2 .filter((df["Study Type"].isNull()) & (df["Number
    of Participants"].isNull())) \
3 .filter(col("Duration").isNull()) \
4 .groupBy("Study Type") \
5 .agg(
6     round(avg("Duration"),2).alias("Media Durata Attesa"
7     ),
8     round(avg("Number of Participants"),2).alias("Media
9     Partecipanti")
10 ) \
    .orderBy("Media Durata Attesa") \
    .show()
```

Codice 10: Durata stimata media e numero medio di partecipanti per tipologia di studio

Study Type	Media Durata Attesa	Media Partecipanti
Non-interventional	436.0	185.0
Active surveillance	487.0	115000.0
Observational	1671.93	2646.27
Interventional	1801.84	649.38
CCT	2648.0	520.0
Other	3531.0	202.0

Figure 7: Durata stimata media e numero medio di partecipanti per tipologia di studio

3.8 Analisi 8: Durata stimata media, numero medio di partecipanti e attenzione mediatica media per ogni categoria HRCS

- **Obiettivo:** Analizzare, per ogni categoria del sistema HRCS, la durata media prevista degli studi, il numero medio di partecipanti richiesti e il livello medio di attenzione mediatica.
- **Descrizione:** Viene creata la colonna *“Duration”*, calcolata come differenza tra *“End Date”* e *“Start Date”*. Il dataset viene filtrato per escludere le righe con valori nulli nei campi: *“Duration”*, *“Number of Participants”*, *“HRCS HC Categories”* e *“Altmetric Attention Score”*. Si estraggono le singole categorie HRCS attraverso uno split, si aggregano i dati per le categorie trovate, e per ogni categoria si calcolano durata media prevista, numero medio di partecipanti e la media dell’Altmetric Attention Score.

```
1 df.withColumn("Duration", datediff(to_date(col("End
   Date"), "yyyy-MM-dd"), to_date(col("Start date"), "
   yyyy-MM-dd")))\
2 .filter(col("Number of Participants").isNull() &
   col("Altmetric Attention Score").isNull() & col
   ("HRCS HC Categories").isNull() & col("Duration
   ").isNull()) \
3 .withColumn("HRCS HC Categorie", explode(split(col("
   HRCS HC Categories"), "; "))) \
4 .groupBy("HRCS HC Categorie") \
5 .agg(
6   round(avg("Duration"),2).alias("Media Durata Attesa"
   ),
7   round(avg("Number of Participants"),2).alias("Media
   Partecipanti"),
8   round(avg("Altmetric Attention Score"),2).alias("
   Media Attenzione Medatica")
9   ) \
10 .orderBy("HRCS HC Categorie") \
11 .show(truncate=False)
```

Codice 11: Durata stimata media, numero medio di partecipanti e attenzione mediatica media per ogni categoria HRCS

HRCS HC Categorie	Media Durata Attesa	Media Partecipanti	Media Attenzione Medatica
Blood	1794.75	1062.25	42.58
Cancer	2326.34	685.58	65.32
Cardiovascular	1745.43	3211.4	67.02
Congenital	823.75	324.06	24.63
Eye	1069.12	517.19	112.14
Generic health relevance	1340.14	1074.57	204.1
Infection	1384.75	1274.52	29.56
Inflammatory and immune system	1659.1	656.61	52.79
Injuries and accidents	1889.3	3829.4	9.6
Mental health	1392.38	354.31	14.65
Metabolic and endocrine	1291.27	1915.84	58.08
Musculoskeletal	1216.46	225.23	26.18
Neurological	1526.06	486.11	65.82
Oral and gastrointestinal	1730.7	1095.35	118.11
Renal and urogenital	1503.97	2256.31	66.09
Reproductive health and childbirth	1950.88	355.29	102.05
Respiratory	1170.28	475.83	59.47
Skin	1005.37	475.0	84.68
Stroke	1811.09	5467.87	29.89

Figure 8: Durata stimata media, numero medio di partecipanti e attenzione mediatica media per ogni categoria HRCS

3.9 Analisi 9: Durata media degli studi sul cancro al seno in funzione dell'attenzione mediatica

- **Obiettivo:** Studiare una possibile correlazione tra l'attenzione mediatica e la durata degli studi clinici relativi al cancro al seno.

- **Descrizione:** Viene creata la colonna *"Duration"*, calcolata come differenza tra *"End Date"* e *"Start Date"*.

Si estraggono le singole categorie di cancro attraverso uno split. Successivamente, il dataset viene filtrato per escludere le righe con valori nulli nei campi: *"Duration"*, *"Number of Participants"* e *"Altmetric Attention Score"*, e mantenere solo le righe in cui la categoria *"Cancer"* corrisponde a *"Breast Cancer"*. I dati vengono aggregati in base al punteggio di attenzione mediatica. Si calcola la durata media per ciascun livello e i risultati vengono ordinati per attenzione mediatica decrescente.

```
1 df.withColumn("Duration", datediff(to_date(col("End
    Date"), "yyyy-MM-dd"), to_date(col("Start date"), "
    yyyy-MM-dd"))) \
2 .withColumn("Cancer", explode(split(col("Cancer Types"
    ), ";")))) \
3 .withColumn("Cancer", trim(col("Cancer"))) \
4 .filter((col("Altmetric Attention Score").isNotNull())
    & (col("Number of Participants").isNotNull()) & (
    col("Cancer") == "Breast Cancer")) \
5 .groupBy("Altmetric Attention Score") \
6 .agg(
7     round(avg("Duration"),2).alias("Media_Durata")
8 ) \
9 .orderBy(col("Altmetric Attention Score").desc()) \
10 .show(30)
```

Codice 12: Durata media degli studi sul cancro al seno in funzione dell'attenzione mediatica

Altmetric Attention Score	Media_Durata
784.0	1188.0
760.0	1324.0
680.0	4338.0
607.0	2471.0
506.0	1626.0
505.0	1891.0
349.0	2062.0
319.0	2261.0
318.0	5111.0
224.0	2223.0
191.0	1814.0
171.0	6232.0
148.0	2699.0
141.0	2387.0
137.0	1658.0
129.0	4383.0
117.0	3129.0
110.0	3289.0
107.0	1956.0
106.0	3684.0
104.0	1910.0
93.0	3739.0
89.0	2138.0
88.0	533.0
82.0	2486.0
80.0	1106.6
74.0	1971.0
73.0	2831.0
66.0	1457.0
64.0	2273.0

only showing top 30 rows

Figure 9: Durata media degli studi sul cancro al seno in funzione dell'attenzione mediatica




Figure 10: Visualizzazione grafica della durata media degli studi sul cancro al seno in funzione dell'attenzione mediatica

3.10 Analisi 10: Top 2 sponsor/collaboratori con più sperimentazioni per ogni tipo di cancro

- **Obiettivo:** Identificare, per ogni tipologia di cancro, le due entità o organizzazioni con il maggior numero di studi finanziati e/o supportati.
- **Descrizione:** Si estraggono le singole categorie di cancro e i singoli sponsor/collaboratori attraverso uno split. Successivamente, il dataset viene filtrato per escludere le righe con valori nulli nei campi: “*Sponsors/Collaborators*” e “*Cancer*”. I dati vengono aggregati per tipologia di cancro e per sponsor e si selezionano i due sponsor/collaboratori con il maggior numero di studi per ciascuna categoria.

```
1 df.withColumn("Cancer", explode(split(col("Cancer Types"), ";"))) \
2   .withColumn("Cancer", trim(col("Cancer"))) \
3   .withColumn("Sponsors/Collaborators", explode(split(col("Sponsors/Collaborators"), ";"))) \
4   .withColumn("Sponsors/Collaborators", trim(col("Sponsors/Collaborators"))) \
5   .filter(col("Cancer").isNotNull() & col("Sponsors/Collaborators").isNotNull()) \
6   .groupBy("Cancer", "Sponsors/Collaborators") \
7   .agg(count("*").alias("Occurrences")) \
8   .withColumn("rank", row_number().over(Window.partitionBy("Cancer").orderBy(col("Occurrences").desc())) \
9   .filter(col("rank") <= 2) \
10  .groupBy("Cancer") \
11  .agg(
12    concat_ws(", ", collect_list("Sponsors/Collaborators")).alias("Top 2 Sponsors/Collaborators"),
13    concat_ws(", ", collect_list(col("Occurrences").cast("string"))).alias("Occurrences")
14  ) \
15  .show(truncate=False)
```

Codice 13: Top 2 sponsor/collaboratori con più sperimentazioni per ogni tipo di cancro

Cancer	Top 2 Sponsors/Collaborators	Occurrences
Bladder Cancer	IRCCS Ospedale San Raffaele, Fondazione IRCCS Istituto Nazionale dei Tumori	95, 88
Bone Cancer, Osteosarcoma / Malignant Fibrous Histiocytoma	Istituto Ortopedico Rizzoli, Fondazione IRCCS Istituto Nazionale dei Tumori	116, 82
Brain Tumor	Istituto Neurologico Carlo Besta, Istituti Fisioterapici Ospitalieri	64, 44
Colon and Rectal Cancer	Istituto Oncologico Veneto, Azienda Ospedaliero-Universitaria Careggi	182, 173
Ear Cancer	Research Site, Fondazione IRCCS Istituto Nazionale dei Tumori	72, 9
Esophageal / Oesophageal Cancer	Research Site, Fondazione IRCCS Istituto Nazionale dei Tumori	100, 38
Eye Cancer	Policlinico S.Orsola-Malpighi	1
Gallbladder Cancer	Istituto Oncologico Veneto, Samsung Medical Center	17, 13
Gastrointestinal Tract	University of Colorado Hospital, IRCCS Ospedale San Raffaele	17, 17
Genital System, Male	Istituto Nazionale Tumori IRCCS "Fondazione G. Pascale", Azienda Ospedaliera Universitaria Pisana	2, 2
Head and Neck Cancer	Fondazione IRCCS Istituto Nazionale dei Tumori, Research Site	100, 72
Kaposi's Sarcoma	Fondazione IRCCS Ca' Granda Ospedale Maggiore Policlinico, Istituto Nazionale per le Malattie Infettive Lazzaro Spallanzani	5, 5
Kidney Cancer	Facility #1, Fondazione IRCCS Istituto Nazionale dei Tumori	86, 92
Laryngeal Cancer	Research Site, Fondazione IRCCS Istituto Nazionale dei Tumori	72, 67
Melanoma	Local Institution, Istituto Nazionale Tumori IRCCS "Fondazione G. Pascale"	364, 247
Myeloma	Azienda Ospedaliero Universitaria Ospedali Riuniti, Policlinico S.Orsola-Malpighi	175, 144
Nervous System	Institut Gustave Roussy, Fondazione IRCCS Istituto Nazionale dei Tumori	15, 14
Neuroblastoma	Istituto Giannina Gaslini, Hospital Universitari i Politècnics La Fe	55, 49
Oral Cavity and Lip Cancer	Fondazione IRCCS Istituto Nazionale dei Tumori, Research Site	95, 72
Ovarian Cancer	Istituto Nazionale Tumori IRCCS "Fondazione G. Pascale", European Institute of Oncology	238, 144

only showing top 20 rows

Figure 11: Top 2 sponsor/collaboratori con più sperimentazioni per ogni tipo di cancro